

# Estabilidad de los algoritmos

CM4F1

Ángel Enrique Ramírez Gutiérrez

aramirezg@uni.edu.pe

Escuela Profesional de Matemática  
Universidad Nacional de Ingeniería

3 de mayo de 2022



## 1. Estabilidad de los algoritmos

### 1.1. Precisión de un algoritmo estable regresivo.

Denotemos por  $\tilde{f}$  a un algoritmo que resuelve el problema  $(f)$ , si  $x$  es un valor de entrada, decimos que  $\tilde{f}(x)$  es preciso si

$$\frac{\|\tilde{f}(x) - f(x)\|}{\|f(x)\|} = O(\epsilon_{\text{máquina}})$$

Sin embargo  $x$  necesita aproximarse y para evitar que los errores de redondeo crezcan al propagarse buscamos que el algoritmo sea estable:

$$\frac{\|\tilde{f}(x) - f(\tilde{x})\|}{\|f(\tilde{x})\|} = O(\epsilon_{\text{máquina}})$$

$$x = \frac{1}{3} + \frac{5}{9} = 2$$
$$\tilde{x} = 0.333$$

para algún  $\tilde{x}$ , tal que

$$\frac{\|\tilde{x} - x\|}{\|x\|} = O(\epsilon_{\text{máquina}})$$

“Un algoritmo estable da resultados cercanos a la solución del problema a pesar del redondeo en los valores de entrada”

Diremos que un algoritmo  $\tilde{f}$  para una problema  $f$  es estable regresivo si para cada  $x \in X$

$$\tilde{f}(x) = f(\tilde{x}) \text{ para algun } \tilde{x} \text{ tal que } \frac{\|\tilde{x} - x\|}{\|x\|} = \underline{O(\epsilon_{\text{máquina}})}$$

“Un algoritmo estable regresivo da el resultado exacto de la solución del problema a pesar del redondeo en los valores de entrada”

## Ejemplo

Considere el algoritmo de eliminación gaussiana  $\hat{f}$  aplicado a matrices cuadradas  $A$ ,  $2 \times 2$  usando cálculos con mantisa de cuatro decimales.

Si  $A = \begin{pmatrix} a_{11} & a_{12} \\ \underline{a_{21}} & \underline{a_{22}} \end{pmatrix}$  entonces el algoritmo opera con redondeo:

Paso 1:  $\underline{m_{21}} = \text{fl}\left(\frac{a_{21}}{a_{11}}\right) \implies m_{21} = \frac{a_{21}}{a_{11}}(1 + \epsilon_{21})$

Paso 2:  $\begin{aligned} a_{22}^{(1)} &= \text{fl}(a_{22} - m_{21}a_{12}) \implies a_{22}^{(1)} = (a_{22} - m_{21}a_{12})(1 + \epsilon_{22}) \\ a_{21}^{(1)} &= \text{fl}(a_{21} - m_{21}a_{11}) \implies a_{21}^{(1)} = (a_{21} - m_{21}a_{11})(1 + \epsilon_{21}) \end{aligned}$

es decir

$$\underline{\hat{f}}(\underline{A}) = \begin{pmatrix} a_{11} & a_{12} \\ a_{21}^{(1)} & a_{22}^{(1)} \end{pmatrix}$$

Ahora buscamos una matriz  $\hat{A} = \begin{pmatrix} a_{11} & a_{12} \\ \hat{a}_{21} & \hat{a}_{22} \end{pmatrix}$  tal que  $\hat{f}(\underline{A}) = \underline{f}(\hat{A})$ , donde  $f$  denota el algoritmo que opera con valores iniciales perturbados.

$$f(\hat{A}) = \begin{pmatrix} a_{11} & a_{12} \\ \underline{0} & \hat{a}_{22} - \frac{\hat{a}_{21}}{a_{11}} a_{12} \end{pmatrix} = \hat{f}(\underline{A}) = \begin{pmatrix} \underline{a_{11}} & \underline{a_{12}} \\ \underline{0} & \underline{a_{22}} \end{pmatrix}$$

y

$$\boxed{a_{21}^{(1)} = 0}$$

$$\boxed{a_{22}^{(1)} = \hat{a}_{22} - \frac{\hat{a}_{21}}{a_{11}} a_{12}}$$

$$\Rightarrow \hat{A} = \begin{pmatrix} a_{11} & a_{12} \\ \hat{a}_{21} & a_{22}^{(1)} + \frac{\hat{a}_{21}}{a_{11}} a_{12} \end{pmatrix}$$

$$a_{22}^{(1)} = \hat{a}_{22} - \frac{\hat{a}_{21}}{a_{11}} a_{12}$$

Para que el algoritmo sea estable regresivo se debe cumplir que.

$$\frac{\|A - \hat{A}\|}{\|A\|} = O(\epsilon)$$

si utilizamos la norma del máximo entonces

$$A - \hat{A} = \begin{pmatrix} 0 & 0 \\ \hat{a}_{21} - a_{21} & a_{22}^{(1)} - a_{22} + \frac{\hat{a}_{21}}{a_{11}} a_{12} \end{pmatrix}$$

como  $\hat{a}_{21} - a_{21} = O(\epsilon)$ :

$$\begin{aligned} a_{22}^{(1)} - a_{22} + \frac{\hat{a}_{21}}{a_{11}} a_{12} &= -\frac{a_{21}}{a_{11}} a_{12} - \frac{a_{21}}{a_{11}} a_{12} \epsilon_{21} + \left(a_{22} - \frac{a_{21}}{a_{11}} a_{12}\right) \epsilon_{22} + \frac{\hat{a}_{21}}{a_{11}} a_{12} \\ &= \underbrace{O(\epsilon)} - \frac{a_{21}}{a_{11}} a_{12} \underbrace{(\epsilon_{21} + \epsilon_{22})} + \underbrace{a_{22} \epsilon_{22}} = \underbrace{O(\epsilon)} \end{aligned}$$

luego  $\frac{\|A - \hat{A}\|}{\|A\|} = O(\epsilon)$

## Ejemplo

Considere la sucesión

$$\begin{cases} x_0 = 1 & x_1 = 1/3 \\ x_{n+1} = \frac{13}{3}x_n - \frac{4}{3}x_{n-1} & n \geq 1 \end{cases} \quad \text{Ecuación a diferencias}$$

genera la sucesión  $x_n = \left(\frac{1}{3}\right)^n$  si perturbamos  $x_n$  por  $\hat{x}_n = x_n + \epsilon_n$  entonces

$$\begin{aligned} \cancel{x_{n+1}} + \epsilon_{n+1} &= \hat{x}_{n+1} = \frac{13}{3}(\cancel{x_n} + \epsilon_n) - \frac{4}{3}(\cancel{x_{n-1}} + \epsilon_{n-1}) \\ \epsilon_{n+1} &= \frac{13}{3}\epsilon_n - \frac{4}{3}\epsilon_{n-1}, \quad \epsilon_0 = \epsilon_1 = \epsilon \end{aligned}$$

Es decir la perturbación se da en los valores iniciales y asumimos que no producen errores de redondeo.



$$X_{n+1} = \frac{13}{3} X_n - \frac{4}{3} X_{n-1}$$

$$X_{n+2} = \frac{13}{3} X_{n+1} - \frac{4}{3} X_n$$

$$X_n = r^n$$

$$\Rightarrow r^{n+2} = \frac{13}{3} r^{n+1} - \frac{4}{3} r^n$$

$$r^2 = \frac{13}{3} r - \frac{4}{3}$$

$$3r^2 = 13r - 4$$

$$3r^2 - 13r + 4 = 0$$

$$\begin{array}{r} 3r \\ r \end{array} \quad \begin{array}{r} -4 \\ -4 \end{array} \Rightarrow r = \frac{1}{3} \quad r = 4$$

$$\Rightarrow X_n = A \left(\frac{1}{3}\right)^n + B(4)^n$$

$$X_0 = A + B = 1 \Rightarrow A + B = 1$$

$$X_1 = \frac{A}{3} + 4B = \frac{1}{3} \Rightarrow A + 12B = 1$$

$$11B = 0$$

$$B = 0$$

$$\Rightarrow A = 1$$

$$\Rightarrow \boxed{X_n = \left(\frac{1}{3}\right)^n}$$

Para resolver la ecuación en diferencias asumimos que  $\epsilon_n = r^n$  entonces  $r^2 - \frac{13}{3}r + \frac{4}{3} = 0$

$$\epsilon_n = A(4)^n + B\left(\frac{1}{3}\right)^n, \quad A, B \in \mathbb{R}$$

o

$$\epsilon_n = \frac{2}{11}(4)^n + \frac{9}{11}\left(\frac{1}{3}\right)^n, \quad A, B \in \mathbb{R}$$

En una máquina de 32 bits el error inicial es cercano  $2^{-24}$  si despreciamos el segundo término entonces  $\epsilon_n \approx \frac{(2)^{2n-23}}{11}$ , así para  $n = 12$  la distorsión sería evidente, como veremos en la siguiente tabla.

$n$	$x_n = (1/3)^n$	$\hat{x}_n$	$x_n - \hat{x}_n$
0	1.00000000	1.00000000	0.00000000
1	0.33333333	0.33333331	0.00000002
2	0.11111111	0.11111102	0.00000009
3	0.03703704	0.03703668	0.00000036
4	0.01234568	0.01234425	0.00000143
5	0.00411523	0.00410950	0.00000572
6	0.00137174	0.00134885	0.00002289
7	0.00045725	0.00036569	0.00009156
8	0.00015242	-0.00021381	0.00036622
9	0.00005081	-0.00141408	0.00146489
10	0.00001694	-0.00584262	0.00585956
11	0.00000565	-0.02343259	0.02343824
12	0.00000188	-0.09375107	0.09375295
13	0.00000063	-0.37501118	0.37501180
14	0.00000021	-1.50004697	1.50004718

## Ejemplo

Considere la sucesión

$$\rightarrow \begin{cases} x_0 = 1 & x_1 = 1/3 \\ x_{n+1} = \frac{4}{3}x_n - \frac{1}{3}x_{n-1} & n \geq 1 \end{cases}$$

que genera la sucesión  $x_n = (\frac{1}{3})^n$ . Si como en el ejemplo anterior consideramos las perturbaciones iniciales, tenemos que

$$\rightarrow \epsilon_{n+1} = \frac{4}{3}\epsilon_n - \frac{1}{3}\epsilon_{n-1}, \quad \epsilon_0 = \epsilon_1 = \epsilon$$

y  $\epsilon_n = A(\frac{1}{3})^n + B(1)^n$ , como  $\epsilon_0 = \epsilon_1 = \epsilon$ ,

$$\epsilon_n = \epsilon$$

$n$	$x_n = (1/3)^n$	$\hat{x}_n$	$x_n - \hat{x}_n$
0	1.00000000	1.00000000	0.00000000 ←
1	0.33333333	0.33333331	0.00000002
2	0.11111111	0.11111108	0.00000003
3	0.03703704	0.03703700	0.00000003
4	0.01234568	0.01234564	0.00000003
5	0.00411523	0.00411519	0.00000003
6	0.00137174	0.00137171	0.00000003
7	0.00045725	0.00045721	0.00000003
8	0.00015242	0.00015238	0.00000003
9	0.00005081	0.00005077	0.00000003
10	0.00001694	0.00001690	0.00000003
11	0.00000565	0.00000561	0.00000003
12	0.00000188	0.00000185	0.00000003
13	0.00000063	0.00000059	0.00000003
14	0.00000021	0.00000017	0.00000003

## Ejemplo

Considere ahora la sucesión

$$\begin{cases} \underline{x_0} = 1 \\ x_{n+1} = \frac{1}{3}x_n \quad n \geq 1 \end{cases}$$

que genera la sucesión  $x_n = (\frac{1}{3})^n$ . Si como en el ejemplo anterior consideramos las perturbaciones iniciales, tenemos que

$$\epsilon_{n+1} = \frac{1}{3}\epsilon_n, \quad \underline{\epsilon_0} = \epsilon$$

luego

$$\epsilon_n = \epsilon 3^{-n}$$

$n$	$x_n = (1/3)^n$	$\hat{x}_n$	$x_n - \hat{x}_n$
0	1.00000000	1.00000000	0.00000000
1	0.33333333	0.33333331	0.00000002
2	0.11111111	0.11111110	0.00000001
3	0.03703704	0.03703703	0.00000000
4	0.01234568	0.01234568	0.00000000
5	0.00411523	0.00411523	0.00000000

### Definición

Si  $\epsilon$  es el error inicial y  $\epsilon(n)$  representa el crecimiento del error después de  $n$  pasos. Si  $|\epsilon(n)| \approx n\epsilon$ , el crecimiento se dice lineal. Si  $|\epsilon(n)| \approx K^n \epsilon$ , el crecimiento se dice exponencial. Si  $K > 1$  el error crece exponencialmente cuando  $n \rightarrow \infty$ ,  $0 < K < 1$ , el error tiende a cero exponencialmente cuando  $n \rightarrow \infty$ .

- El ejemplo 2 muestra un algoritmo inestable con error exponencialmente creciente.
- El ejemplo 3 muestra un algoritmo estable con error estacionario.
- El ejemplo 4 muestra un algoritmo estable con error exponencialmente decreciente.

## Ejemplo

Considere  $y_n = \int_0^1 x^n e^x dx$ ,  $n \geq 0$ , si integramos por partes

$$y_{n+1} = e - (n+1)y_n$$

Si  $\epsilon$  es la perturbación inicial y  $\epsilon_n$  es el error asociado a  $y_n$  entonces

$$\hat{y}_{n+1} = e - (n+1)(y_n + \epsilon_n) = y_{n+1} - (n+1)\epsilon_n$$

luego  $\epsilon_{n+1} = -(n+1)\epsilon_n$   $= (n+1)n\epsilon_{n-1} = (-1)^{n+1}n!\epsilon$ .

$$\epsilon_n \rightarrow +\infty, \text{ cuando } n \rightarrow +\infty$$

Vemos que el algoritmo es inestable.





- Numerical Analysis: Mathematics of Scientific Computing, Third Edition David Kincaid: University of Texas at Austin, Austin, TX, Ward Cheney.
- Numerical Methods Using Matlab, 4th Edition John H. Mathews, California State University, Fullerton, Kurtis K. Fink, Northwest Missouri State University
- Numerical Lineal Algebra. Lloyd N. Trefethen and David Bau, III xii+361 pages. SIAM, 1997
- Elementary Numerical Analysis, 3rd Edition Kendall Atkinson, Weimin Han